

گزارش نهایی:

تحليل و پیش‌بینی بیماری قلبی بر اساس دیتاست Heart Disease Prediction

تهیه‌کننده: آرزو راستکار

تاریخ: ۱۳ دسامبر ۲۰۲۵

هدف پروژه: بررسی دیتاست ۲۷۰ نمونه‌ای بیماران قلبی، شناسایی عوامل خطر، و ساخت مدل classification برای پیش‌بینی Presence/Absence بیماری قلبی با دقت بالا (تقریباً ۸۵٪).

ابزارها: Python (Pandas, Scikit-learn, Seaborn, Matplotlib)

دیتاست: ۱۳ ویژگی دموگرافیک/بالینی

(Age, Sex, Chest pain type, BP, Cholesterol, FBS over 120, EKG results, Max HR, Exercise angina, ST depression, Slope of ST, Number of vessels fluoro, Thallium) + هدف. (Heart Disease: Absence/Presence)

۱. مقدمه و بررسی اولیه داده

دیتاست شامل ۲۷۰ بیمار (۵۶٪ Absence، ۴۴٪ Presence) هست - کمی imbalance، اما با stratify مدیریت شد. هیچ missing value ای نداره (تمیز).

آمار توصیفی کلیدی : (describe())

ویژگی	میانگین	انحراف استاندارد	حداقل	حداکثر
Age	۵۴/۴۳	۹/۱۱	۲۹	۷۷
Sex (زن، ۱=مرد=۰)	۰/۶۸	۰/۴۷	۰	۱
Chest pain type	۳/۱۶	۰/۹۲	۱	۴
BP	۱۳۰/۳۴	۱۷/۰۶	۹۴	۲۰۰
Cholesterol	۲۴۹/۶۶	۵۱/۸۳	۱۴۹	۵۶۴
Max HR	۱۵۰/۱۸	۲۲/۹۰	۷۱	۲۰۲
ST depression	۱/۰۵۰	۱/۱۶	۰	۶/۲
Thallium	۴/۷۰	۱/۹۴	۳	۷

مشاهدات: مردان (Sex = 1) بیشتر درگیرن؛ کلسترول بیشتر از ۲۵۰ در ۵۰٪ Presence دیده می‌شه.

۲. تحلیل اکتشافی (EDA)

-توزیع کلاس: ۱۵۰ Absence (۵۶٪)، ۱۲۰ Presence (۴۴٪)

-همبستگی با هدف (باینری): Thallium (۰,۵۲۵، قوی مثبت - عامل خطر عروقی)، Max HR (-۰,۴۱۹)، محافظ - ضربان پایین خطرناک).

- جدول همبستگی کلیدی:

همبستگی	ویژگی
۰/۵۲۵	Thallium
۰/۴۵۵	Number of vessels fluro
۰/۴۱۹	Exercise angina
۰/۴۱۸	ST depression
۰/۴۱۷	Chest pain type
-۰/۴۱۹	Max HR

-Heatmap: Visualization همبستگی رسم شد - هیچ multicollinearity شدید (< 0.8) دیده نشد.

-تفسیر: تمرکز روی $Thallium < 5$ و $ST depression < 1$ برای غربالگری.

۳. پیش پردازش

- Split: $20/80$ (Train: ۲۱۶، Test: ۵۴) با stratify (تعداد ۵۶٪ Absence در train).

- Scaling: StandardScaler روی train (میانگین ۰، واریانس ۱) - برای تعدیل واریانس (مثل Cholesterol)

۴. مدل سازی و ارزیابی

دو مدل Logistic Regression : baseline (LR با scaling) و Random Forest (RF بدون).

-نتایج: Baseline

مدل	دقت (Test)	Recall Presence	F1 Presence
LR	۸۵/۱۹٪	۹۲٪	۰/۸۵
RF	۸۱/۴۸٪	۸۳٪	۰/۸۰

-اهمیت ویژگی ها (از RF):

اهمیت	ویژگی	رتبه
۰/۱۳۰	Chest pain type	۱
۰/۱۲۰	Max HR	۲
۰/۱۱۰	ST depression	۳
۰/۱۰۰	Thallium	۴

-تفسیر: LR برتره (ساده، interpretable)؛ RF برای feature selection عالی. هر دو overfitting ندارند.

۵. Tuning مدل

- GridSearchCV برای LR (cv=5): بهترین {'C': 0.1, 'penalty': 'l2'} - قوی regularization.

- دقت CV : ۸۴,۲۶% (stable)

- دقت Tuned Test : ۸۵,۱۹% (بدون افت)

- جدول CV Scores

C	CV دقت l2
۰.۱	۸۴,۲۶%
۱	۸۲,۸۸%
۱۰	۸۱,۹۶%

۶. نتیجه گیری و توصیه ها

- بهترین مدل: Tuned LR (۸۵% دقت، ۹۲% Recall Presence) - مناسب بیمارستان برای غربالگری.

- عوامل کلیدی خطر: Thallium بالا، Chest pain type = ۴، ST depression (شدید).

- محدودیت ها: دیتاست کوچک (۲۷۰) - نیاز به داده بیشتر؛ imbalance کم، اما SMOTE می تونه کمک کنه.

- توصیه ها:

- تمرکز روی بیماران $Max\ HR < ۵۵$ سال با $Max\ HR < ۱۴۰$ و $کلسترول < ۳۰۰$

تحلیل جامع بر اساس نمودارهای رسم شده: پیش بینی و عوامل خطر بیماری قلبی

در این تحلیل، با استفاده از دیتاست Heart Disease Prediction شامل ۲۷۰ بیمار و ۱۴ ویژگی دموگرافیک و بالینی، روابط، توزیع ها و عملکرد مدل های پیش بینی را از طریق visualization های متنوع بررسی کردیم. ماتریس همبستگی (Heatmap) نشان می دهد که ویژگی هایی مانند Thallium (با همبستگی ۰,۵۲) و ST depression (۰,۴۲) بیشترین ارتباط مثبت با وجود بیماری قلبی (Presence) دارند، در حالی که حداکثر ضربان قلب (Max HR) با همبستگی منفی -۰,۴۲ به عنوان عامل محافظ عمل می کند؛ این الگوها حاکی از اهمیت مشکلات عروقی و الکتریکی قلب در پیش بینی است، بدون وجود multicollinearity شدید (همبستگی های بالای ۰,۸ نادر است).

Histogram کلی داده ها (data.hist) توزیع ویژگی های عددی را آشکار می سازد، جایی که سن (Age) توزیع نرمالی با میانگین ۵۴ سال دارد، اما کلسترول (Cholesterol) skew راست نشان می دهد (با مقادیر بالا در ۲۰٪ موارد)، که با boxplot BP و Cholesterol همخوانی دارد: در گروه Presence، میانه کلسترول به ۲۷۰ می رسد (بالاتر از ۲۴۰ در Absence) و outliers (خارج از IQR) در کلسترول ≈ 20 مورد را تشکیل می دهند، که می تواند نشان دهنده بیماران پرخطر با سطوح غیرطبیعی باشد.

Histogram Age با KDE (kernel density estimation) تأیید می کند که توزیع سن پیک در ۶۰-۵۰ سال دارد و KDE منحنی صاف نرمال را ترسیم می کند، که با 3D Scatter (Age-Cholesterol-BP) هم راستاست: در این visualization سه بعدی، نقاط قرمز (Presence) عمدتاً در ناحیه سن بالا، کلسترول < 300 و BP < 140 cluster می شوند، در حالی که نقاط آبی (Absence) پراکندگی گسترده تری نشان می دهند، و این الگو بر نقش سن و کلسترول به عنوان عوامل تجمعی خطر تأکید دارد.

Pairplot کلی روابط pairwise را برجسته می کند، جایی که scatterplot Max HR vs Thallium نشان دهنده جداسازی واضح کلاس ها است (Presence با Thallium بالا و Max HR پایین)، و این با scatterplot KMeans (۳ کلاستر، $k \approx 431$) همخوانی دارد: کلاسترها بر اساس سن و کلسترول جدا می شوند، با کلاستر قرمز (Presence) در مقادیر بالا، که پیشنهاد می کند KMeans می تواند برای unsupervised grouping بیماران پرخطر مفید باشد.

Bar-plot توزیع کلاس imbalance (countplot) را آشکار می‌کند (۱۲۰ Presence vs ۱۵۰ Absence).
۵۶٪ به ۴۴٪)، و countplot Heart Disease by Sex نشان می‌دهد که مردان (Sex=۱) ۱۷۰٪ موارد Presence را تشکیل می‌دهند (در مقابل ۵۰٪ در زنان)، که heatmap cross-tab (Sex vs Disease) با مقادیر ۵۰/۷۰ تأیید می‌کند و بر نابرابری جنسیتی در خطر بیماری تأکید دارد – این یافته‌ها حاکی از نیاز به غربالگری جنسیت‌محور است.

در بخش مدل‌سازی، line plot KNN scores ($K=1-20$) دقت را به عنوان تابعی از همسایگان نشان می‌دهد، با پیک ۸۹٪ در $K=18$ ، که نشان‌دهنده بهینه‌سازی hyperparameter برای KNN است و overfitting در Kهای پایین (به دلیل نویز) را برجسته می‌کند. Bar plot SVC kernels مقایسه kernelها را ترسیم می‌کند، جایی که linear با ۹۱٪ دقت برتر است (۸۸٪:poly، ۸۸٪:RBF، ۸۵٪:sigmoid)، و این برتری به دلیل روابط خطی قوی در داده (مانند همبستگی Thallium) است.

Line plot Decision Tree max_features دقت را بر اساس تعداد ویژگی‌ها نشان می‌دهد، با بهبود از ۷۰٪ در max_features=۱ به ۸۵٪ در max_features=۲، که حاکی از سادگی مدل DT در این دیتاست است و نیاز به pruning برای جلوگیری از overfitting را پیشنهاد می‌کند. Bar plot Random Forest estimators دقت را به عنوان تابعی از تعداد درخت‌ها (۱۰-۱۰۰۰) ترسیم می‌کند، با تثبیت در ۸۷٪ برای ۲۰۰+ درخت، که نشان‌دهنده ensemble learning به عنوان روش robust برای مدیریت نویز (مانند outliers کلسترول) است.

در مجموع، این visualizationها الگویی جامع را آشکار می‌سازند: عوامل خطر اصلی (Thallium بالا، کلسترول <300 ، سن <55 ، جنسیت مرد) با دقت ۹۱٪ توسط SVC linear پیش‌بینی می‌شوند، در حالی که clustering KMeans و imbalance جنسیتی بر لزوم مداخلات هدفمند (مانند غربالگری مردان بالای ۵۰ سال) تأکید دارند؛ این یافته‌ها نه تنها دقت مدل‌ها را (۸۵-۹۱٪) تأیید می‌کنند، بلکه کاربرد بالینی را برای تشخیص زودهنگام برجسته می‌سازند، با پتانسیل بهبود از طریق SMOTE برای تعادل کلاس‌ها.